Лабораторная работа №1

Разведочный анализ данных. Исследование и визуализация данных **(EDA)**

Выполнил: Дюжев Степан ИУ5Ц-83Б

Подготовка

Выполним импорт необходимых библиотек

```
In [1]:
```

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Comment this if the data visualisations doesn't work on your side
%matplotlib inline

plt.style.use('bmh')
```

Импортируем данные из датасета

```
In [2]:
```

```
df = pd.read_csv('train.csv')
df.head()
```

Out[2]:

	ld	MSSubClass	MSZoning	LotFrontage	LotArea	Street	Alley	LotShape	LandContour	Utilities	LotConfig	LandSlope	ı
0	1	60	RL	65.0	8450	Pave	NaN	Reg	Lvi	AllPub	Inside	Gtl	
1	2	20	RL	80.0	9600	Pave	NaN	Reg	Lvi	AllPub	FR2	GtI	
2	3	60	RL	68.0	11250	Pave	NaN	IR1	Lvi	AllPub	Inside	Gtl	
3	4	70	RL	60.0	9550	Pave	NaN	IR1	Lvi	AllPub	Corner	Gtl	
4	5	60	RL	84.0	14260	Pave	NaN	IR1	Lvl	AllPub	FR2	Gtl	

5 rows × 81 columns

Просмотрим информацию о столбцах

```
In [3]:
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1460 entries, 0 to 1459
Data columns (total 81 columns):
# Column Non-Null Count Dtype
---
                   -----
   Id
                  1460 non-null
0
                                int64
1 MSSubClass 1460 non-null int64
2 MSZoning 1460 non-null object
                 1460 non-null object
                                float64
3 LotFrontage 1201 non-null
```

4	Lotarea	146U non-null	int64
5	Street	1460 non-null	object
6	Alley	91 non-null	object
7	LotShape	1460 non-null	object
8	LandContour	1460 non-null	object
9	Utilities	1460 non-null	object
10	LotConfig	1460 non-null	object
11	LandSlope	1460 non-null	object
12	Neighborhood	1460 non-null	object
13	Condition1	1460 non-null	object
14	Condition2	1460 non-null	object
15	BldgType	1460 non-null	object
16	HouseStyle	1460 non-null	object
17	OverallQual	1460 non-null	int64
18	OverallCond	1460 non-null	int64
19	YearBuilt	1460 non-null	int64
20	YearRemodAdd	1460 non-null	int64
21	RoofStyle	1460 non-null	object
22	RoofMatl	1460 non-null	object
23	Exterior1st	1460 non-null	object
24 25	Exterior2nd	1460 non-null	object
26	MasVnrType MasVnrArea	1452 non-null 1452 non-null	object float64
27	ExterQual	1460 non-null	object
28	ExterCond	1460 non-null	object
29	Foundation	1460 non-null	object
30	BsmtQual	1423 non-null	object
31	BsmtCond	1423 non-null	object
32	BsmtExposure	1422 non-null	object
33	BsmtFinType1	1423 non-null	object
34	BsmtFinSF1	1460 non-null	int64
35	BsmtFinType2	1422 non-null	object
36	BsmtFinSF2	1460 non-null	int64
37	BsmtUnfSF	1460 non-null	int64
38	TotalBsmtSF	1460 non-null	int64
39	Heating	1460 non-null	object
40	HeatingQC	1460 non-null	object
41	CentralAir	1460 non-null	object
42	Electrical	1459 non-null	object
43	1stFlrSF	1460 non-null	int64
44	2ndFlrSF	1460 non-null	int64
45 46	LowQualFinSF GrLivArea	1460 non-null	int64
46 47	BsmtFullBath	1460 non-null 1460 non-null	int64 int64
48	BsmtHalfBath	1460 non-null	int64
49	FullBath	1460 non-null	int64
50	HalfBath	1460 non-null	int64
51	BedroomAbvGr	1460 non-null	int64
52	KitchenAbvGr	1460 non-null	int64
53	KitchenQual	1460 non-null	object
54	TotRmsAbvGrd	1460 non-null	int64
55	Functional	1460 non-null	object
56	Fireplaces	1460 non-null	int64
57	FireplaceQu	770 non-null	object
58	GarageType	1379 non-null	object
59	GarageYrBlt	1379 non-null	float64
60	GarageFinish	1379 non-null	object
61	GarageCars	1460 non-null	int64
62	GarageArea	1460 non-null	int64
63	GarageQual	1379 non-null	object
64 65	GarageCond	1379 non-null	object
66	PavedDrive WoodDeckSF	1460 non-null 1460 non-null	object int64
67	OpenPorchSF	1460 non-null	int64
68	EnclosedPorch	1460 non-null	int64
69	3SsnPorch	1460 non-null	int64
70	ScreenPorch	1460 non-null	int64
71	PoolArea	1460 non-null	int64
72	PoolQC	7 non-null	object
73	Fence	281 non-null	object
74	MiscFeature	54 non-null	object
75	MiscVal	1460 non-null	int64
7.7	15 0 7 1	1 1 / / 1 1	1 1 6 4

```
/6 Mosora
                   146U non-null
                                  int64
 77 YrSold
                  1460 non-null
                                  int64
                  1460 non-null
 78 SaleType
                                object
79 SaleCondition 1460 non-null
                                  object
80 SalePrice
                  1460 non-null
                                  int64
dtypes: float64(3), int64(35), object(43)
memory usage: 924.0+ KB
```

Мы можем заметить, что в некоторых столбцах очень много **NaN** значений, при анализе такие столбцы не релевантны, поэтому мы удалим их

удалим столбец id так как он не несет никаой полезной для исследования информации

In [4]:

```
del df["Id"]
```

In [5]:

```
# df.count() не включате NaN значения
df2 = df[[column for column in df if df[column].count() / len(df) >= 0.3]]
print("List of dropped columns:", end=" ")
for c in df.columns:
    if c not in df2.columns:
        print(c, end=", ")
print('\n')
df = df2
```

List of dropped columns: Alley, PoolQC, Fence, MiscFeature,

Теперь давайте посмотрим, как распределяются цены на жилье


In [6]:


```
print(df['SalePrice'].describe())
plt.figure(figsize=(9, 8))
sns.distplot(df['SalePrice'], color='g', bins=100, hist_kws={'alpha': 0.4});
```

```
1460.000000
         180921.195890
mean
          79442.502883
std
min
          34900.000000
25%
         129975.000000
50%
         163000.000000
75%
         214000.000000
         755000.000000
max
Name: SalePrice, dtype: float64
```

/usr/local/lib/python3.7/dist-packages/seaborn/distributions.py:2557: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please adapt you rode to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).

warnings.warn(msg, FutureWarning)





С помощью этой информации мы видим, что цены искажены вправо, а некоторые выбросы лежат выше ~500 000. В конце концов мы захотим избавиться от них, чтобы получить нормальное распределение независимой переменной (SalePrice) исследования

Распределение числовых данных

рассмотрим распределение всех функций путем их построения

Для этого давайте сначала перечислим все типы наших данных из нашего набора данных и возьмем только числовые:

```
In [7]:
```

```
list(set(df.dtypes.tolist()))
Out[7]:
```

[dtype('float64'), dtype('int64'), dtype('O')]

```
In [8]:
```

```
df_num = df.select_dtypes(include = ['float64', 'int64'])
df_num.head()
```


Out[8]:


	MSSubClass	LotFrontage	LotArea	OverallQual	OverallCond	YearBuilt	YearRemodAdd	MasVnrArea	BsmtFinSF1	BsmtFi
0	60	65.0	8450	7	5	2003	2003	196.0	706	
1	20	80.0	9600	6	8	1976	1976	0.0	978	
2	60	68.0	11250	7	5	2001	2002	162.0	486	
3	70	60.0	9550	7	5	1915	1970	0.0	216	
4	60	84.0	14260	8	5	2000	2000	350.0	655	
4										Þ

Построим графики

In [9]:

```
df_num.hist(figsize=(16, 20), bins=50, xlabelsize=8, ylabelsize=8);
```





Корреляция признаков

Теперь мы попытаемся найти, какие функции сильно коррелируют с **SalePrice**. Мы будем хранить их в списке под названием **golden_features_list**. Для этого мы повторно используем наш набор данных **df_num**.

```
In [10]:
```


```
df num corr = df num.corr()['SalePrice'][:-1] # -1 потому что последний столбец и есть S
alePrice
golden_features_list = df_num_corr[abs(df_num_corr) > 0.5].sort_values(ascending=False)
print("{} сильно коррелирущих признаков с SalePrice:\n{}".format(len(golden_features_lis
t), golden features list))
10 сильно коррелирущих признаков с SalePrice:
OverallQual
                0.790982
GrLivArea
                0.708624
GarageCars
                0.640409
GarageArea
                0.623431
TotalBsmtSF
                0.613581
1stFlrSF
                0.605852
FullBath
                0.560664
```


TotkmsAbvGrd 0.533/23 YearBuilt 0.522897 YearRemodAdd 0.507101 Name: SalePrice, dtype: float64

Теперь у нас есть список сильно коррелированных значений, но этот список неполон, поскольку мы знаем, что на корреляцию влияют выбросы.

- Построим график числовых характеристик и посмотрим, какие из них имеют очень мало выбрасов и их можно объяснить
- Удалим выбросы из этих функций и посмотрим, какие из них могут иметь хорошую корреляцию без выбросов

In [11]:





Можем определить некоторые отношения, большинство из них, по-видимому, имеют линейную связь с "SalePrice", и если мы внимательно посмотрим на данные, то увидим, что многие точки данных расположены на "x = 0", что может указывать на отсутствие такого признака в доме.

давайте удалим эти значения и повторим процесс поиска коррелированных значений заново

In [12]:

Waadbaaker. A 10270601227520677

```
import operator
individual features df = []
for i in range(0, len(df num.columns) - 1): # -1 потому что последний столбец и есть Sal
ePrice
    tmpDf = df num[[df num.columns[i], 'SalePrice']]
    tmpDf = tmpDf[tmpDf[df_num.columns[i]] != 0]
    individual features df.append(tmpDf)
all correlations = {feature.columns[0]: feature.corr()['SalePrice'][0] for feature in in
dividual features df}
all correlations = sorted(all correlations.items(), key=operator.itemgetter(1))
for (key, value) in all correlations:
   print("{:>15}: {:>15}".format(key, value))
  KitchenAbvGr: -0.13920069217785566
      HalfBath: -0.08439171127179887
    MSSubClass: -0.08428413512659523
   OverallCond: -0.0778558940486776
         YrSold: -0.028922585168730426
   BsmtHalfBath: -0.028834567185481712
      PoolArea: -0.014091521506356928
  BsmtFullBath: 0.011439163340408634
        MoSold: 0.04643224522381936
      3SsnPorch: 0.06393243256889079
   OpenPorchSF: 0.08645298857147708
       MiscVal: 0.08896338917298924
     Fireplaces: 0.1216605842136395
      BsmtUnfSF: 0.16926100049514192
   BedroomAbvGr: 0.18093669310849045
```

```
WOOQDECKSE: U.IJS/UUUIZS/JZUU//
   BsmtFinSF2: 0.19895609430836586
EnclosedPorch: 0.2412788363011751
  ScreenPorch: 0.25543007954878405
      LotArea: 0.2638433538714063
 LowQualFinSF: 0.3000750165550133
  LotFrontage: 0.35179909657067854
   MasVnrArea: 0.4340902197568926
   BsmtFinSF1: 0.4716904265235731
  GarageYrBlt: 0.48636167748786213
 YearRemodAdd: 0.5071009671113867
    YearBuilt: 0.5228973328794967
 TotRmsAbvGrd: 0.5337231555820238
     FullBath: 0.5745626737760816
     1stFlrSF: 0.6058521846919166
   GarageArea: 0.6084052829168343
  TotalBsmtSF: 0.6096808188074366
   GarageCars: 0.6370954062078953
     2ndFlrSF: 0.6733048324568383
    GrLivArea: 0.7086244776126511
  OverallOual: 0.7909816005838047
```

Мы нашли еще одно сильно коррелированное значение, немного очистив данные. Теперь **golden_features_list** выглядит так:

```
In [13]:
```

```
golden_features_list = [key for key, value in all_correlations if abs(value) >= 0.5]
print("There is {} strongly correlated values with SalePrice:\n{}".format(len(golden_features_list), golden_features_list))
```

```
There is 11 strongly correlated values with SalePrice:
['YearRemodAdd', 'YearBuilt', 'TotRmsAbvGrd', 'FullBath', '1stFlrSF', 'GarageArea', 'Tota
lBsmtSF', 'GarageCars', '2ndFlrSF', 'GrLivArea', 'OverallQual']
```

Заключение

Изучая корреляцию между числовыми значениями, мы обнаружили **11** признаков, которые имеют сильную связь с ценой дома. Кроме корреляции, мы не нашли никакой заметной закономерности на данных, которые не коррелируют.

Отношение объекта к объекту


Попытка изобразить все числовые характеристики на парном графике **pairplot** займет у нас слишком много времени и будет трудно интерпретировать. Мы можем попытаться увидеть, связаны ли некоторые переменные между собой, а затем объяснить их связь с помощью здравого смысла.

```
In [ ]:
```



- 0.75 - 0.50

1.00



Q -> Q (количественные связи)

In [14]:

Out[14]:

	LotFrontage	LotArea	MasVnrArea	BsmtFinSF1	BsmtFinSF2	TotalBsmtSF	1stFlrSF	2ndFlrSF	LowQualFinSF	GrLivArea
0	65.0	8450	196.0	706	0	856	856	854	0	1710
1	80.0	9600	0.0	978	0	1262	1262	0	0	1262
2	68.0	11250	162.0	486	0	920	920	866	0	1786
3	60.0	9550	0.0	216	0	756	961	756	0	1717
4	84.0	14260	350.0	655	0	1145	1145	1053	0	2198
4										Þ

In [15]:

```
features_to_analyse = [x for x in quantitative_features_list if x in golden_features_lis
t]
features_to_analyse.append('SalePrice')
features_to_analyse
```

Out[15]:

```
['TotalBsmtSF',
'1stFlrSF',
'2ndFlrSF',
'GrLivArea',
```

```
'F'ullBath',
'TotRmsAbvGrd',
'GarageCars',
'GarageArea',
'SalePrice']
```

распределение

```
In [ ]:
```

```
fig, ax = plt.subplots(round(len(features to analyse) / 3), 3, figsize = (18, 12))
for i, ax in enumerate(fig.axes):
      if i < len(features to analyse) - 1:</pre>
            sns.regplot(x=features to analyse[i], y='SalePrice', data=df[features to analyse]
, ax=ax)
   800000
                                                                                                 700000
                                                 600000
                                                                                                 600000
   600000
                                                  500000
                                                                                                 500000
SalePrice
                                                                                                 400000
                                                  400000
   400000
                                                 300000
                                                                                                 300000
                                                 200000
                                                                                                 200000
   200000
                                                 100000
                                                                                                 100000
                                                       500 1000 1500 2000 2500 3000 3500 4000 4500
1stFlrSF
                                                                                                                       1000 1250 1500 1750 2000
                          3000
                                4000
                                      5000
                                                                                                              500
                      TotalBsmtSE
   700000
                                                  700000
                                                                                                 700000
                                                 600000
                                                                                                 600000
   600000
   500000
                                                 500000
                                                                                                 500000
   400000
                                                  400000
                                                                                                 400000
                                                  300000
                                                 200000
   200000
                                                                                                 200000
  100000
                                                 100000
                                                                                                 100000
                                                      8.0
           1000
                          3000
                                 4000
                                                                       FullBath
                                                                                                                    TotRmsAbvGrd
                                                                                                   1.0
                                                  700000
   700000
                                                                                                   0.8
   600000
                                                 600000
  500000
                                                  500000
                                                                                                   0.6
                                                  400000
   400000
  300000
                                                  300000
   200000
                                                  200000
```

такие функции, как TotalBsmtSF, 1stFlrSF, GrLivArea, имеют большой разброс

100000

С -> Q (Отношение категориального к количественному)

In [16]:

100000

8.0 0.5 1.0

2.0 2.5 3.0 3.5

GarageCars

```
# quantitative features list[:-1] as the last column is SalePrice and we want to keep it
categorical features = [a for a in quantitative features list[:-1] + df.columns.tolist()
if (a not in quantitative features list[:-1]) or (a not in df.columns.tolist())]
df_categ = df[categorical features]
df categ.head()
```

0.2

0.8.0

1400

1000 1200

GarageArea

Out[16]:

	MSSubClass	MSZoning	Street	LotShape	LandContour	Utilities	LotConfig	LandSlope	Neighborhood	Condition1	Condi
0	60	RL	Pave	Reg	Lvl	AllPub	Inside	GtI	CollgCr	Norm	ı
1	20	RL	Pave	Reg	Lvl	AllPub	FR2	GtI	Veenker	Feedr	1
2	60	RL	Pave	IR1	Lvl	AllPub	Inside	GtI	CollgCr	Norm	ľ
•	70	Di.	D	ID4	1.4	AUDL	^	ОTI	^d	Massa	

In [17]:

```
df_not_num = df_categ.select_dtypes(include = ['O'])
print('There is {} non numerical features including:\n{}'.format(len(df_not_num.columns))
, df_not_num.columns.tolist()))
```


There is 39 non numerical features including:
['MSZoning', 'Street', 'LotShape', 'LandContour', 'Utilities', 'LotConfig', 'LandSlope',
'Neighborhood', 'Condition1', 'Condition2', 'BldgType', 'HouseStyle', 'RoofStyle', 'RoofMatl', 'Exterior1st', 'Exterior2nd', 'MasVnrType', 'ExterQual', 'ExterCond', 'Foundation',
'BsmtQual', 'BsmtCond', 'BsmtExposure', 'BsmtFinType1', 'BsmtFinType2', 'Heating', 'HeatingQC', 'CentralAir', 'Electrical', 'KitchenQual', 'Functional', 'FireplaceQu', 'GarageType', 'GarageFinish', 'GarageQual', 'GarageCond', 'PavedDrive', 'SaleType', 'SaleCondition'

In [18]:

```
plt.figure(figsize = (10, 6))
ax = sns.boxplot(x='BsmtExposure', y='SalePrice', data=df_categ)
plt.setp(ax.artists, alpha=.5, linewidth=2, edgecolor="k")
plt.xticks(rotation=45)
```

Out[18]:

(array([0, 1, 2, 3]), <a list of 4 Text major ticklabel objects>)




In [19]:

```
plt.figure(figsize = (12, 6))
ax = sns.boxplot(x='SaleCondition', y='SalePrice', data=df_categ)
plt.setp(ax.artists, alpha=.5, linewidth=2, edgecolor="k")
plt.xticks(rotation=45)
```

Out[19]:

(array([0, 1, 2, 3, 4, 5]), <a list of 6 Text major ticklabel objects>)





Посмотрим на их распределение

```
In [20]:
fig, axes = plt.subplots(round(len(df_not_num.columns) / 3), 3, figsize=(12, 30))
for i, ax in enumerate(fig.axes):
     if i < len(df not num.columns):</pre>
           ax.set xticklabels(ax.xaxis.get majorticklabels(), rotation=45)
           sns.countplot(x=df_not_num.columns[i], alpha=0.7, data=df_not_num, ax=ax)
fig.tight_layout()
                                             1500
   1000
                                                                                         750
                                             1000
                                          count
                                                                                      count
count
                                                                                         500
    500
                                              500
                                                                                         250
      0
                                                0
                                                                                          0
                     Clally
                                                       697E
                                                                                              QED
                                                                        Œ,
                                                                                                              PS
                                                                                                                       183
         か
                                                                                                       P
                                                                                                        LotShape
                                                               Street
                   MSZoning
                                             1500
                                                                                        1000
   1000
                                             1000
count
                                          count
                                                                                     count
                                                                                         500
    500
                                              500
      0
                                                0
                                                                                          0
                                                                                                               CultSac
                                                                                                                      493
                                 MS
                                                                      HOSENS
                                                                                                    492
                                                       AllPub
                         ON
          ŵ
                 LandContour
                                                              Utilities
                                                                                                        LotConfig
                                              200
                                                                                       1000
   1000
count
                                                                                     count
                                            count
                                              100
                                                                                         500
    500
      0
                                                                                          0
                     1000
           Ø
                                СgN
                  LandSlope
                                                                                                       Condition1
                                                           Neighborhood
   1500
                                             1000
                                                                                         600
900 th
                                          count
                                                                                      count
                                                                                        400
                                              500
    500
                                                                                         200
      0
                                                0
                                                                                                   15Fin
                                                                                               Story
                                                  Fam
                                                                                                       15Uni
           Artery RRM
                   Feedl Posh
                           POSA RRAN RRAS
                  Condition2
                                                                                                       HouseStyle
                                                             BldgType
                                             1500
   1000
                                                                                         400
                                             1000
                                                                                      200
200
                                          count
count
    500
                                              500
                                                0
      0
                                                                                          0
```



w wer on our our drought on our Sale Type

Northal Barotril Partial Bulland Block Family
SaleCondition